第一节 RAG简介

一、什么是RAG?

1.1 核心定义

RAG（Retrieval-Augmented Generation）是一种**融合信息检索与文本生成**的技术范式。其核心逻辑是：在大型语言模型（LLM）生成文本前，先通过检索机制从外部知识库中动态获取相关信息，并将检索结果融入生成过程，从而提升输出的准确性和时效性[1][2][3]。

> 当然RAG的定义会随着技术的发展而拓展，所以当前定义仅作为基本框架的确立。

💡 **RAG本质**：在LLM生成文本之前，先从**外部知识库**中检索相关信息，作为上下文辅助生成更准确的回答。

1.2 技术原理

- **双阶段架构**：

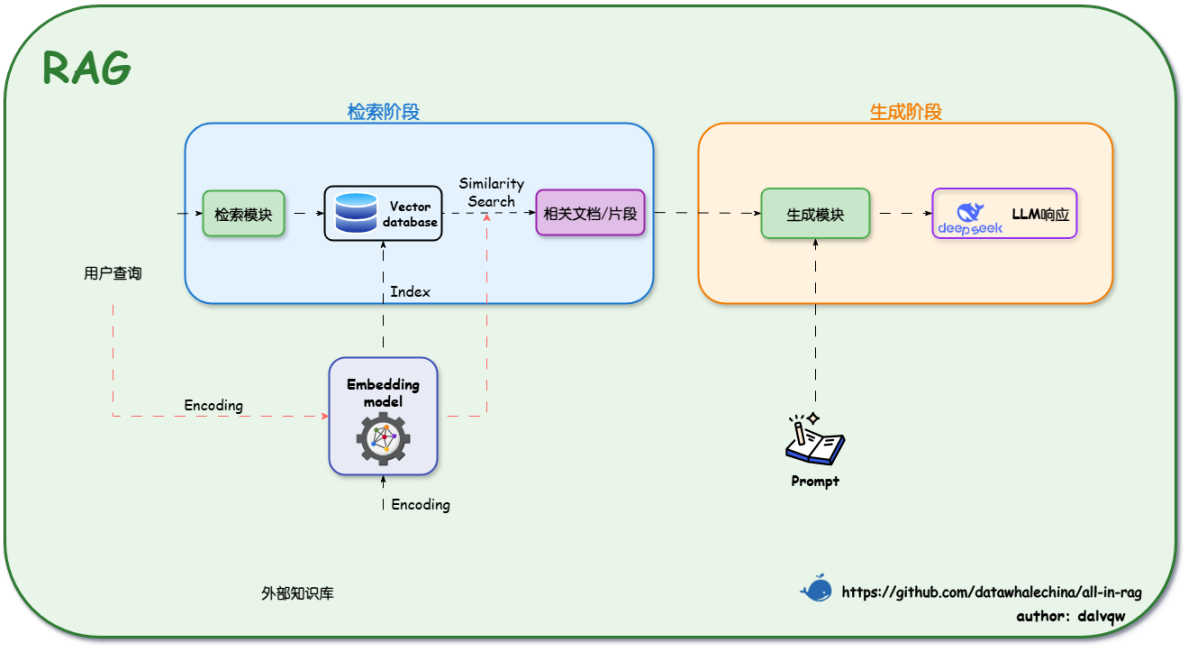

- **关键组件**：
  1. **索引（Indexing）** 📑：将非结构化文档（PDF/Word等）分割为片段，通过嵌入模型转换为向量数据。
  2. **检索（Retrieval）** 🔍：基于查询语义，从向量数据库召回最相关的文档片段（Context）。
  3. **生成（Generation）** ✨：将检索结果作为上下文输入LLM，生成自然语言响应。

1.3 技术演进分类

RAG技术按照复杂度可划分为[4]：

初级RAG	高级RAG	模块化RAG
基础"索引-检索-生成"流程	增加数据清洗流程	灵活集成搜索引擎
简单文档分块	元数据优化	强化学习优化
基本向量检索机制	多轮检索策略	知识图谱增强
-	提升准确性和效率	支持复杂业务场景

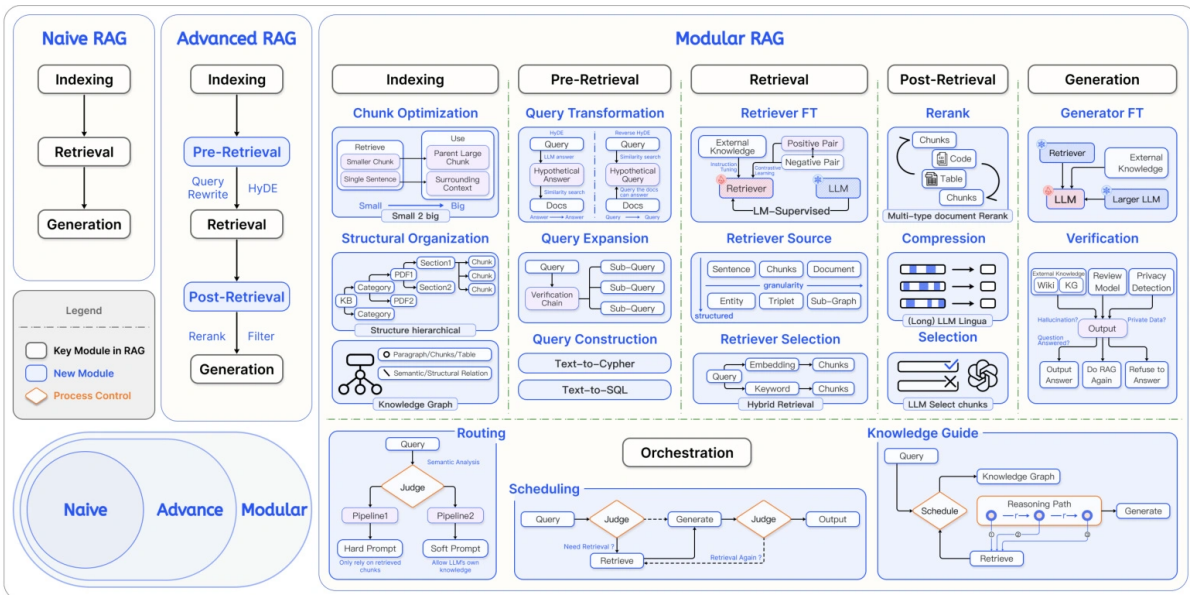

二、为什么要使用RAG[5]？

2.1 解决LLM的核心局限

问题	RAG的解决方案
静态知识局限	实时检索外部知识库，支持动态更新
幻觉（Hallucination）	基于检索内容生成，错误率降低
领域专业性不足	引入领域特定知识库（如医疗/法律）
数据隐私风险	本地化部署知识库，避免敏感数据泄露

2.2 关键优势

1. **准确性提升**

- 知识基础扩展：补充LLM预训练知识的不足，增强对专业领域的理解
- 降低幻觉现象：通过提供具体参考材料，减少无中生有的情况
- 可溯源引用：支持引用原始文档，提高输出内容的可信度和说服力

2. **实时性保障**

- 动态知识更新：知识库内容可以独立于模型进行实时更新和维护
- 减少时滞性：规避LLM预训练数据截止日期带来的知识时效性问题

3. **成本效益**

- 避免频繁微调：相比反复微调LLM，维护知识库成本更低
- 降低推理成本：针对特定领域问题，可使用更小的基础模型配合知识库
- 资源消耗优化：减少存储完整知识在模型权重中的计算资源需求
- 快速适应变化：新信息或政策更新只需更新知识库，无需重训练模型

4. **可扩展性**

- 多源集成：支持从不同来源和格式的数据中构建统一知识库
- 模块化设计：检索组件可独立优化，不影响生成组件

2.3 适用场景风险分级

> 以下是RAG技术在不同风险等级场景中的适用性

风险等级	案例	RAG适用性
低风险	翻译/语法检查	高可靠性
中风险	合同起草/法律咨询	需结合人工审核
高风险	证据分析/签证决策	需严格质量控制机制

三、如何上手RAG?

3.1 基础工具链选择

开发框架

- **LangChain**：提供预置RAG链（如rag_chain），支持快速集成LLM与向量库
- **LlamaIndex**：专为知识库索引优化，简化文档分块与嵌入流程

向量数据库

- **Milvus**：开源高性能向量数据库
- **FAISS**：轻量级向量搜索库
- **Pinecone**：云服务向量数据库

3.2 四步构建最小可行系统（MVP）

1. **数据准备**
    - 格式支持：PDF、Word、网页文本等
    - 分块策略：按语义（如段落）或固定长度切分，避免信息碎片化
2. **索引构建**
    - 嵌入模型：选取开源模型（如text-embedding-ada-002）或微调领域专用模型
    - 向量化：将文本分块转换为向量存入数据库
3. **检索优化**
    - 混合检索：结合关键词（BM25）与语义搜索（向量相似度）提升召回率
    - 重排序（Rerank）：用小模型筛选Top-K相关片段（如Cohere Reranker）
4. **生成集成**
    - 提示工程：设计模板引导LLM融合检索内容
    - LLM选型：GPT、Claude、Ollama等（按成本/性能权衡）

3.3 新手友好方案

- **LangChain4j Easy RAG**：仅需上传文档，自动处理索引与检索
- **FastGPT**：开源知识库平台，可视化配置RAG流程
- **GitHub模板**：如"TinyRAG"项目[6]，提供完整代码

3.4 进阶调优方向

评估指标

```
检索质量：上下文相关性（Context Relevance）
生成质量：答案忠实度（Faithfulness）、事实准确性
```

性能优化

```
索引分层：对高频数据启用缓存机制
多模态扩展：支持图像/表格检索
```

> RAG技术仍在快速发展中，可以持续关注学术和工业界的最新进展！

参考文献

---

1. Genesis, J. (2025). *Retrieval-Augmented Text Generation: Methods, Challenges, and Applications*. ↩
2. Gao et al. (2023). *Retrieval-Augmented Generation for Large Language Models: A Survey*. ↩
3. Lewis et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. ↩
4. Gao et al. (2024). *Modular RAG: Transforming RAG Systems into LEGO-like Reconfigurable Frameworks*. ↩
5. *RAG: Why Does It Matter, What Is It, and Does It Guarantee Accuracy?*. ↩
6. *TinyRAG: GitHub项目*. ↩